Asignatura	Datos del alumno	Fecha
Ingeniería para el Procesado Masivo de Datos	Apellidos:	
	Nombre:	

Anexo: creación de un clúster en Google Cloud

Cuando se dispone de un clúster en un entorno real, generalmente se instala, en cada uno de los nodos, una distribución del sistema operativo Linux y, sobre este, Spark, Hadoop (HDFS) y el resto de herramientas (Kafka, Hive, etc.). Para que funcionen correctamente, se configura cada una de ellas indicando las direcciones IP del resto de nodos y algunos detalles, como qué nodo es el *namenode* y cuál el *datanode* (HDFS), qué nodo de Spark hace el papel de máster, etc. La figura 1 representa una instalación en un clúster con tres nodos, a los que hemos llamado *unircluster-m* (nodo que hace el papel de «máster», en el sentido de que en él se instalan JupyterLab y el *namenode* de HDFS, y de que no contiene ningún bróker de Kafka para dejarlo más libre), *unircluster-w-0* y *unircluster-w-1*.

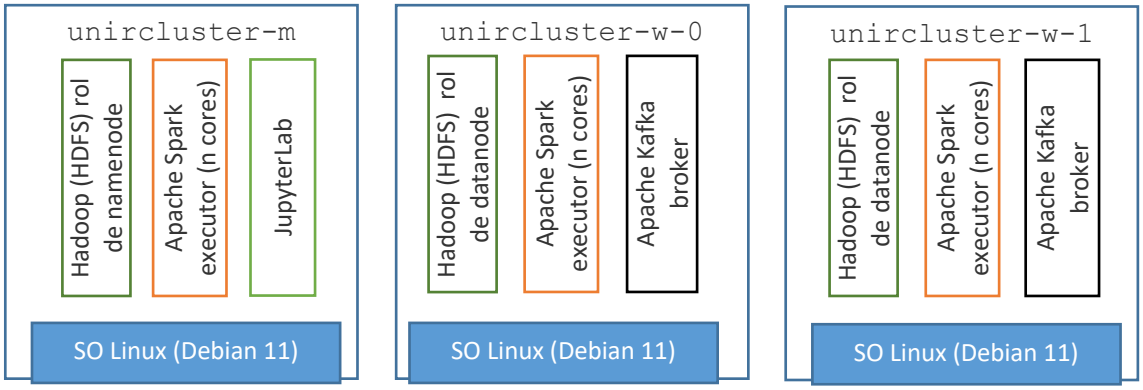

Figura 1. Ejemplo de despliegue en un clúster real con tres nodos físicos que usan el sistema operativo Linux.

Crearemos un clúster exactamente como el de la figura anterior en la plataforma Google Cloud, mediante su herramienta Dataproc. Google nos da numerosas facilidades, ya que despliega automáticamente las herramientas que necesitamos usar (HDFS, Spark, Kafka y JupyterLab) y marca las distintas opciones en una interfaz gráfica. Debemos tener en cuenta que **dicho clúster se crea al vuelo: está**

levantado durante un cierto período de tiempo, en el que podemos configurarlo, y después se desmantela automáticamente.

- **Paso 1:** entramos en http://cloud.google.com/free y pulsamos en «Empezar gratis». Nos solicitará un correo de Gmail, los datos personales y una tarjeta de crédito. Google nos regala $300 de saldo que se pueden gastar en 90 días. Teniendo en cuenta el poco uso que le daremos en esta asignatura, nunca llegaremos a consumir más allá de unos pocos dólares y no se cargará nada.

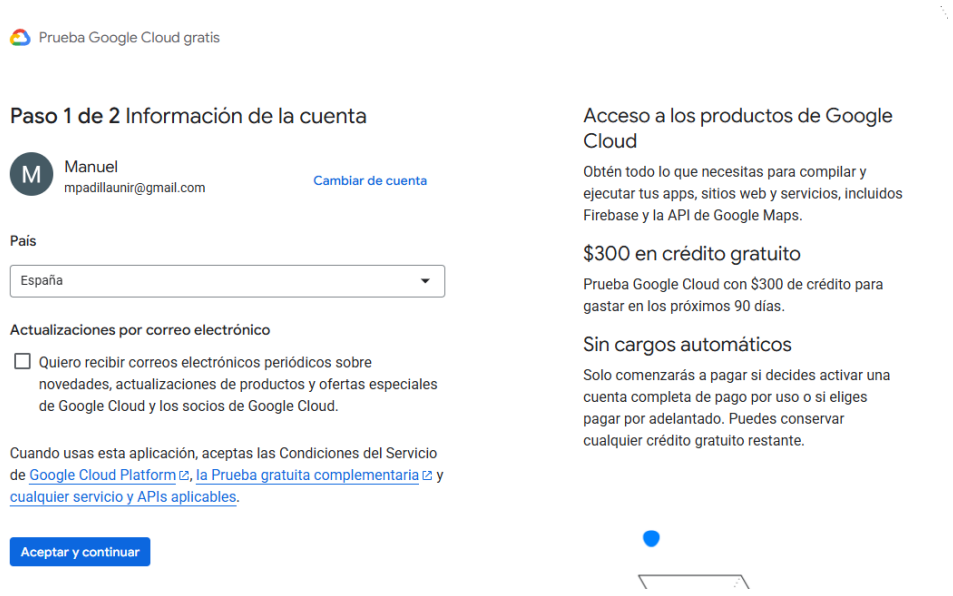

- **Paso 2**: accedemos a https://console.cloud.google.com/ y activamos la API. Para ello, en la barra del buscador de API de Google Cloud, escribiremos «dataproc» y haremos clic sobre el servicio que aparecerá como resultado de la búsqueda. Una vez que estemos en la página principal del servicio, activamos la API.

- **Paso 3**: accedemos al menú lateral y buscamos **STORAGE → Cloud Storage → Buckets**. Hacemos clic en la parte superior, en **CREATE**.

- Elegimos el nombre del *bucket* (el que que queramos, siempre que esté libre).
- Seleccionamos dónde almacenar los datos: **Location type → Region**. En el menú inferior: **Location → europe-west1**
- No hay que modificar ninguna otra opción.
- Pulsamos abajo el botón azul **CREATE**.

Esto creará un *bucket* de Google Cloud Storage (GCS), que es un sistema de almacenamiento persistente gratuito que **sí mantiene el contenido que hayamos almacenado en él, aunque el clúster sea desmantelado**. Por eso, lo usaremos para guardar tanto los *datasets* como los *notebooks* de JupyterLab.

- **Paso 4**: accedemos, en el menú lateral, al apartado **BIG DATA (MACRODATOS) → Dataproc → Clusters**. Aunque es posible crear el clúster a través de la interfaz gráfica, las opciones que hay que especificar para este curso son muchas y es relativamente fácil equivocarse, por lo que aquí vamos a pulsar directamente en **el botón para abrir el Google Cloud Shell** (terminal de Google para introducir comandos de Google que manejan cualquier componente) que aparece en la **esquina superior derecha** (ver imagen) y pegaremos el comando siguiente.

Hemos señalado en rojo y en negrita las opciones **<u>que cada alumno debe modificar</u>**:

- Nombre que queramos dar a nuestro clúster.
- **Nombre de nuestro *bucket*** de Google Cloud Storage que hemos creado antes.

- **Identificador** de nuestro proyecto de Google Cloud. **No es el nombre del proyecto** sino el **identificador** que aparece en **letras amarillas** al abrir la terminal. Debe ser del tipo **XXXX-YYYY-12345** (dos palabras separadas por guión, y al final un número, por ejemplo el ID de mi proyecto es impactful-pilot-269111 pero el vuestro será otro distinto que tenéis que mirar, copiar y pegar aquí)
- Tiempo máximo, en segundos, que queremos que permanezca levantado (por ejemplo 4 horas = 14400 s).

```
gcloud beta dataproc clusters create nombrecluster --enable-component-
gateway --bucket nombreBucket --region us-west1 --master-machine-type n1-
standard-2 --master-boot-disk-size 300 --num-workers 2 --worker-machine-type
n1-standard-2 --worker-boot-disk-size 300 --image-version 2.1-debian11 --
properties spark:spark.jars.packages=org.apache.spark:spark-sql-kafka-0-
10_2.12:3.3.2 --optional-components JUPYTER,ZOOKEEPER --max-age 14400s --
initialization-actions 'gs://goog-dataproc-initialization-actions-us-
west1/kafka/kafka.sh' --project id-XXXX-YYYY-12345
```

IMPORTANTE: comprobad que el comando se ha pegado correctamente (todo el comando es una sola línea) y no os habéis dejado algún carácter suelto o se ha comido algún espacio en blanco al pegar. No se debe modificar la región porque no funcionan todas exactamente igual. Ha habido problemas de servicio en Europa.

IMPORTANTE (SI DA ERROR DE PERMISOS):

Asignar el rol **Dataproc Worker** al Service Account:

```
gcloud projects add-iam-policy-binding project-54929e07-632d-4347-ad6 \
 --member="serviceAccount:690701712988-compute@developer.gserviceaccount.com" \
 --role="roles/dataproc.worker"
```

Si da error por GCS:

```
gcloud projects add-iam-policy-binding project-54929e07-632d-4347-ad6 \
 --member="serviceAccount:690701712988-compute@developer.gserviceaccount.com" \
 --role="roles/storage.objectAdmin"
```

Asignatura	Datos del alumno	Fecha
Ingeniería para el Procesado Masivo de Datos	Apellidos:	
	Nombre:	

IMPORTANTE: si el comando devolviera el error indicando explícitamente que no hay suficientes recursos libres en la región seleccionada, se puede probar a lanzar de nuevo en la región europe-west2. Recuerda cambiar esto tanto en el argumento --region como al final del comando en initialization-actions para reemplazar us-west1 por europe-west2.

Una vez creado el cluster, vamos al menú **Clusters** y, cuando el clúster aparezca con una marca en verde, pulsamos sobre su nombre, vamos a la pestaña **WEB INTERFACES** y hacemos click abajo en JupyterLab.

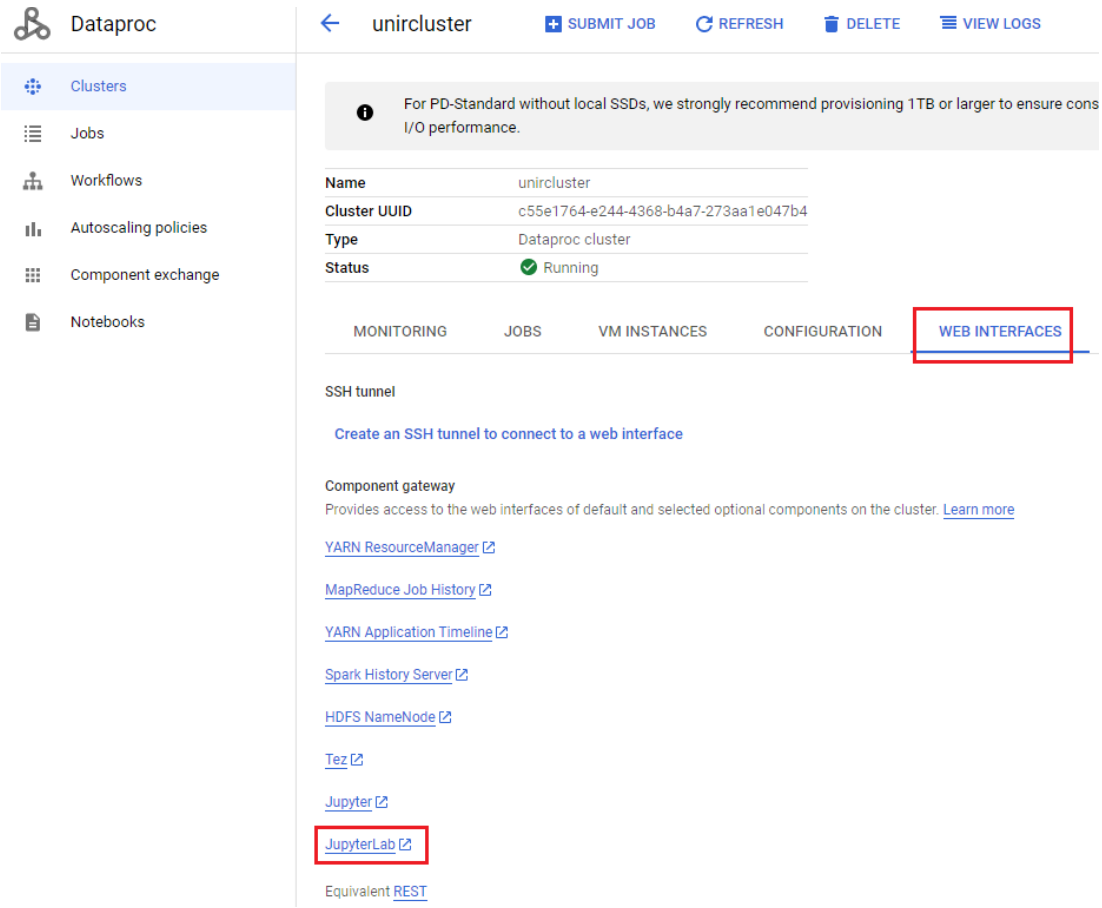

Asignatura	Datos del alumno	Fecha
Ingeniería para el Procesado Masivo de Datos	Apellidos:	
	Nombre:	

Si al hacer click en JupyterLab, se abriese una pestaña con un error, es algo temporal y si probáis de nuevo al cabo de un rato, se abrirá correctamente.