Ingeniería para el Procesado Masivo de Datos

PER 14624 Noviembre 2025

Presentación de la asignatura

PSU IA + DE

00 – ¿De qué vamos a hablar?

- Presentación
- Objetivos
- Temas
- Actividades
- Las clases en directo
- Recursos
- Herramientas software y lenguajes de programación

01 –Presentación

Manuel Padilla García

Profesor

- Ingeniero informático centrado en el análisis de datos.
- Pertenezco al Área de Ciencias de la Computación y Tecnología de ESIT
-
  - Programa Superior Universitario en IA y Data Engineering
  - Máster Universitario en Análisis y Visualización de Datos Masivos
  - Director de TFM

02 – Objetivos de la asignatura

- Comprender la necesidad de tecnologías Big Data como HDFS y Hadoop
- Conocer las tecnologías del ecosistema Hadoop y algunos de sus componentes: HDFS, Spark, Hive, Kafka, Impala …
- Analizar las diferencias entre ellos, para qué sirven y cuándo implementarlos
- Conocer las distintas plataformas Cloud: Azure, Google Cloud, AWS

03 – Temas

Bloque 1. Entorno de trabajo del ecosistema Hadoop: Temas 1 y 2

¿Qué vamos a aprender?

- Introducción a las tecnologías Big Data
- HDFS

03 – Temas

Bloque 2. Procesando datos con Spark: Temas 3, 4 y 5

¿Qué vamos a aprender?

- Spark I (Arquitectura y RDDs)
- Spark II (Spark SQL)
- Spark III (MLlib, Structure Streaming)

03 – Temas

Bloque 3. : Tecnologías de Data Warehouse: Temas 6 y 7

¿Qué vamos a aprender?

- Apache Kafka
- Hive e Impala

03 – Temas

Bloque 4. : Plataformas de computación en la nube: Temas 8, 9 y 10

¿Qué vamos a aprender?

- Cloud Computing I – Microsoft Azure
- Cloud Computing II – Amazon Web Services
- Cloud Computing III – Google Cloud Platform

04 – Actividades

Asignatura	Datos del alumno	Fecha
Ingeniería para el Procesado Masivo de Datos	Apellidos:	
	Nombre:	

Actividad 1. Structured Streaming y Kafka

*Esta actividad **no** está asociada al Proyecto transversal, pero debe obligatoriamente utilizar el mismo dataset de **flights** de la Actividad 1.*

Con esta actividad, los estudiantes pondrán en práctica los conocimientos estudiados en las clases de teoría acerca del manejo de Apache Spark (módulo Streaming) y Kafka. Completarán un ejercicio sencillo que involucra las dos tecnologías y que los ayudará a entender mejor el propósito de cada una y a verlas funcionando en un caso concreto.

A continuación, describimos el trabajo que debe llevar a cabo el estudiante y, en la siguiente sección, presentaremos la infraestructura disponible en la que se realizarán las tareas, así como unas orientaciones sobre cómo utilizarla.

Descripción de la actividad

Se compone de dos partes diferentes. En cada una, hemos desglosado la explicación en pasos para facilitar su resolución.

Entrega 16-02-2026

04 – Actividades

Asignatura	Datos del alumno	Fecha
Ingeniería para el Procesado Masivo de Datos	Apellidos:	
	Nombre:	

Actividad 2. Análisis exploratorio con Google BigQuery

Actividad del Proyecto (actividad grupal)

Esta actividad está asociada al proyecto transversal del título y, para su desarrollo, tendrás que utilizar obligatoriamente el siguiente recurso:

- Conjunto de dataset sales formado por los ficheros *features.csv, sales.csv y stores.csv* del Catálogo de Datos del proyecto.

Objetivos

A través de esta actividad, los estudiantes podrán poner en práctica los conceptos estudiados en las clases de teoría acerca de las herramientas ofrecidas por los proveedores de cloud computing, aplicándolos a un análisis exploratorio de un conjunto de datos. El objetivo es iniciarse en el manejo de un sistema de Data Warehouse de tipo SaaS, en concreto el software BigQuery de Google Cloud, muy propicio para realizar análisis sin necesidad de conocimientos de programación. A

La actividad 02 es grupal. Se os enviará un correo con la asignación de los grupos con suficiente antelación

Entrega 16-02-2026

05 – Clases en directo

¿Cómo van a ser las clases en directo?

- Introducción y breve resumen de la clase anterior
- Explicación teórica
- Planteamiento de problema y solución
- Introducción de la siguiente clase y despedida

- Clase de presentación
- Clases de temario
- Clases de refuerzo

Documentación

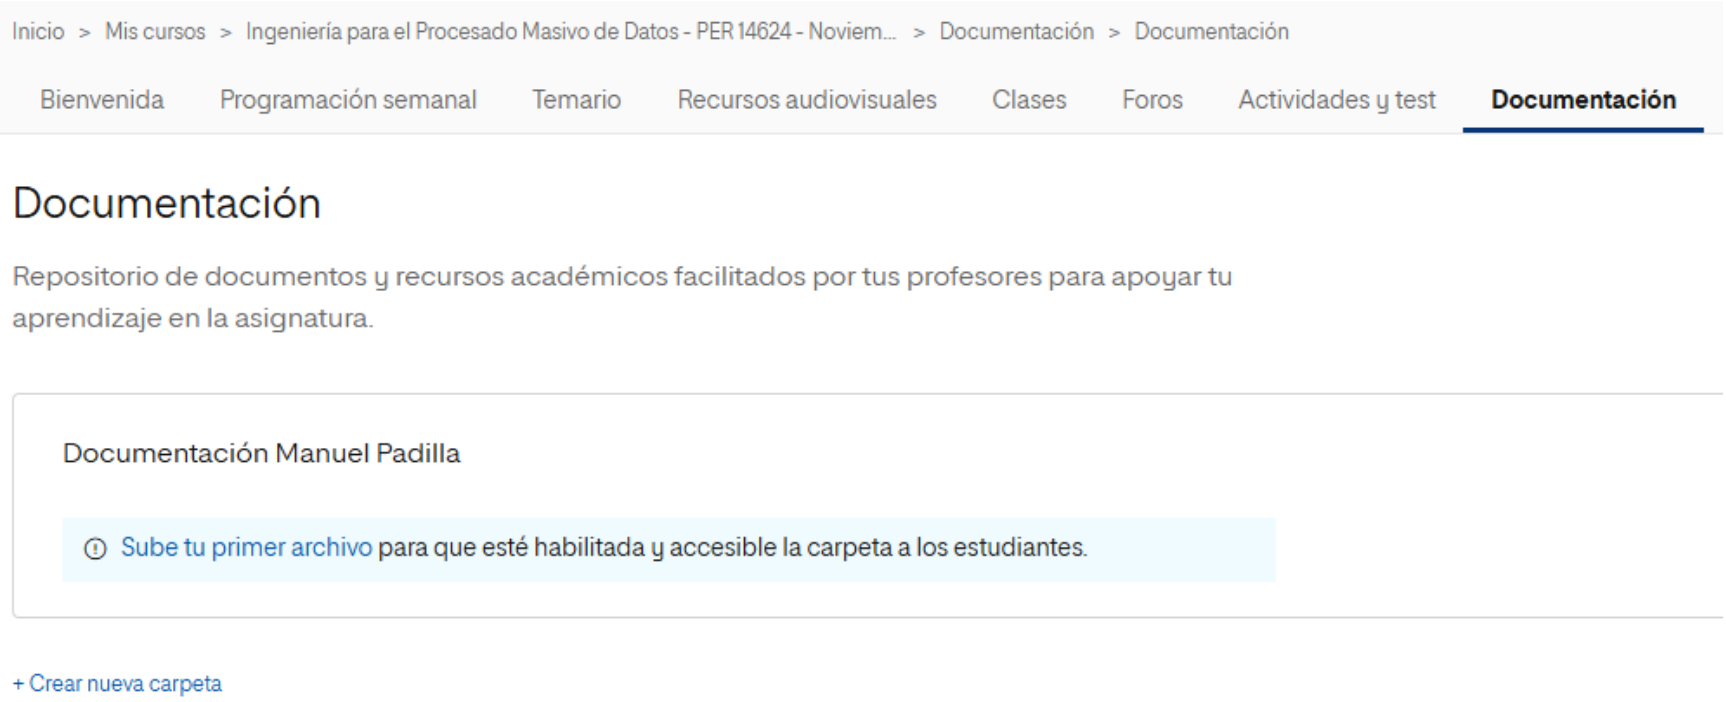

06 – Recursos

Foros

Inicio > Mis cursos > Ingeniería para el Procesado Masivo de Datos - PER 14624 - Noviem... > Foros > Pregúntale a tu profesor

Atrás

Pregúntale a tu profesor

Podéis utilizar este foro para exponer todas aquellas dudas que os vayan surgiendo a lo largo del cuatrimestre o plantearme cualquier tipo de cuestión relativa a los contenidos de esta asignatura. ¡Ánimo!

Crear un nuevo hilo

	Creador	Último mensaje	Mensajes	Suscripción
Foro de dudas - Actividad 2	MANUEL PADILLA GARCIA	MANUEL PADILLA GARCIA 4/11/25	0 | 0 no leídos	
Foro de dudas – Actividad 1	MANUEL PADILLA GARCIA	MANUEL PADILLA GARCIA 4/11/25	0 | 0 no leídos	
Foro de dudas – Bloque 4: Plataformas de computación en la nube (Temas 8, 9 y 10)	MANUEL PADILLA GARCIA	MANUEL PADILLA GARCIA 4/11/25	0 | 0 no leídos	
Foro de dudas – Bloque 3: Tecnologías de DataWarehouse y mensajería (Temas 6 y 7)	MANUEL PADILLA GARCIA	MANUEL PADILLA GARCIA 4/11/25	0 | 0 no leídos	
Foro de dudas – Bloque 2: Procesando datos con Spark (Temas 3, 4 y 5)	MANUEL PADILLA GARCIA	MANUEL PADILLA GARCIA 4/11/25	0 | 0 no leídos	

07 – Evaluación

Actividad 1 (4 puntos)

Actividad 2 (4 puntos)

Test final (2 final)

08 – Herramientas y lenguajes de programación

- **Jupyter notebook :** entorno interactivo que permite escribir y ejecutar código, visualizar datos y documentar análisis en un mismo lugar.

- **Google Cloud Storage (GCS):** servicio de almacenamiento escalable en la nube de Google para guardar y acceder a grandes volúmenes de datos desde cualquier aplicación.

- **Spark:** motor distribuido de procesamiento de datos en memoria, diseñado para ejecutar tareas de análisis masivo de forma rápida y eficiente.

- **Kafka:** plataforma distribuida de *streaming* que permite transmitir, procesar y almacenar flujos de datos en tiempo real.

- **BigQuery:** servicio *serverless* de Google que permite ejecutar consultas SQL ultra rápidas sobre grandes volúmenes de datos.

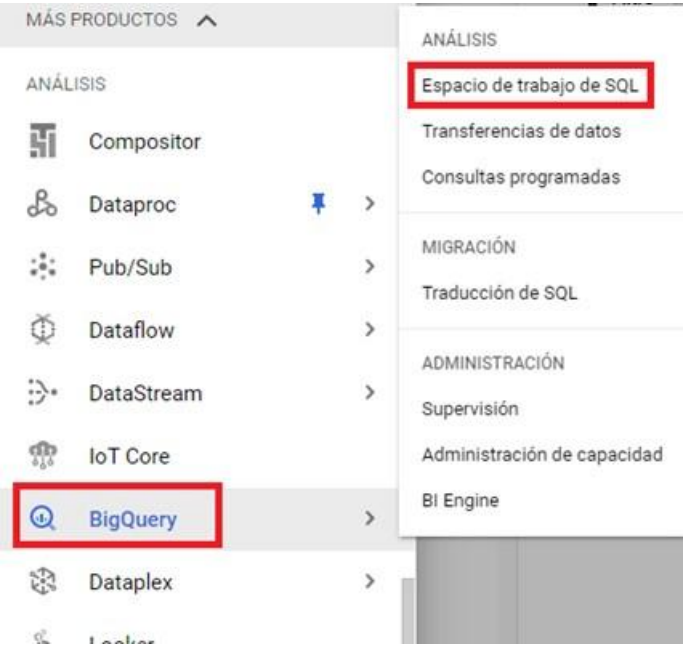

Dudas y preguntas

unir

LA UNIVERSIDAD
EN INTERNET

www.unir.net