Tema 1. Introducción a las Tecnologías Big Data

PER 14624 Noviembre 2025

Objetivos del tema

- Comprender cuáles son las necesidades actuales de procesamiento de datos, sus causas y cómo son solventadas por las tecnologías big data.
- Entender el concepto de clúster de ordenadores y cuáles son las principales tecnologías distribuidas capaces de explotarlo.
- Conocer las herramientas principales que componen el ecosistema Hadoop, cuál es la finalidad de cada una y cómo se relacionan entre sí.

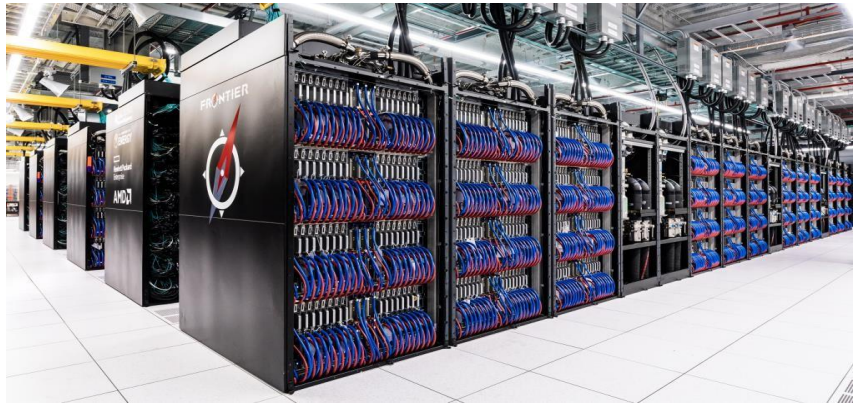

Motivación de las tecnologías Big Data

- Vivimos en una sociedad **interconectada**: la **era del cliente**
- El 90 % de los datos existentes se generaron en los últimos 2 años

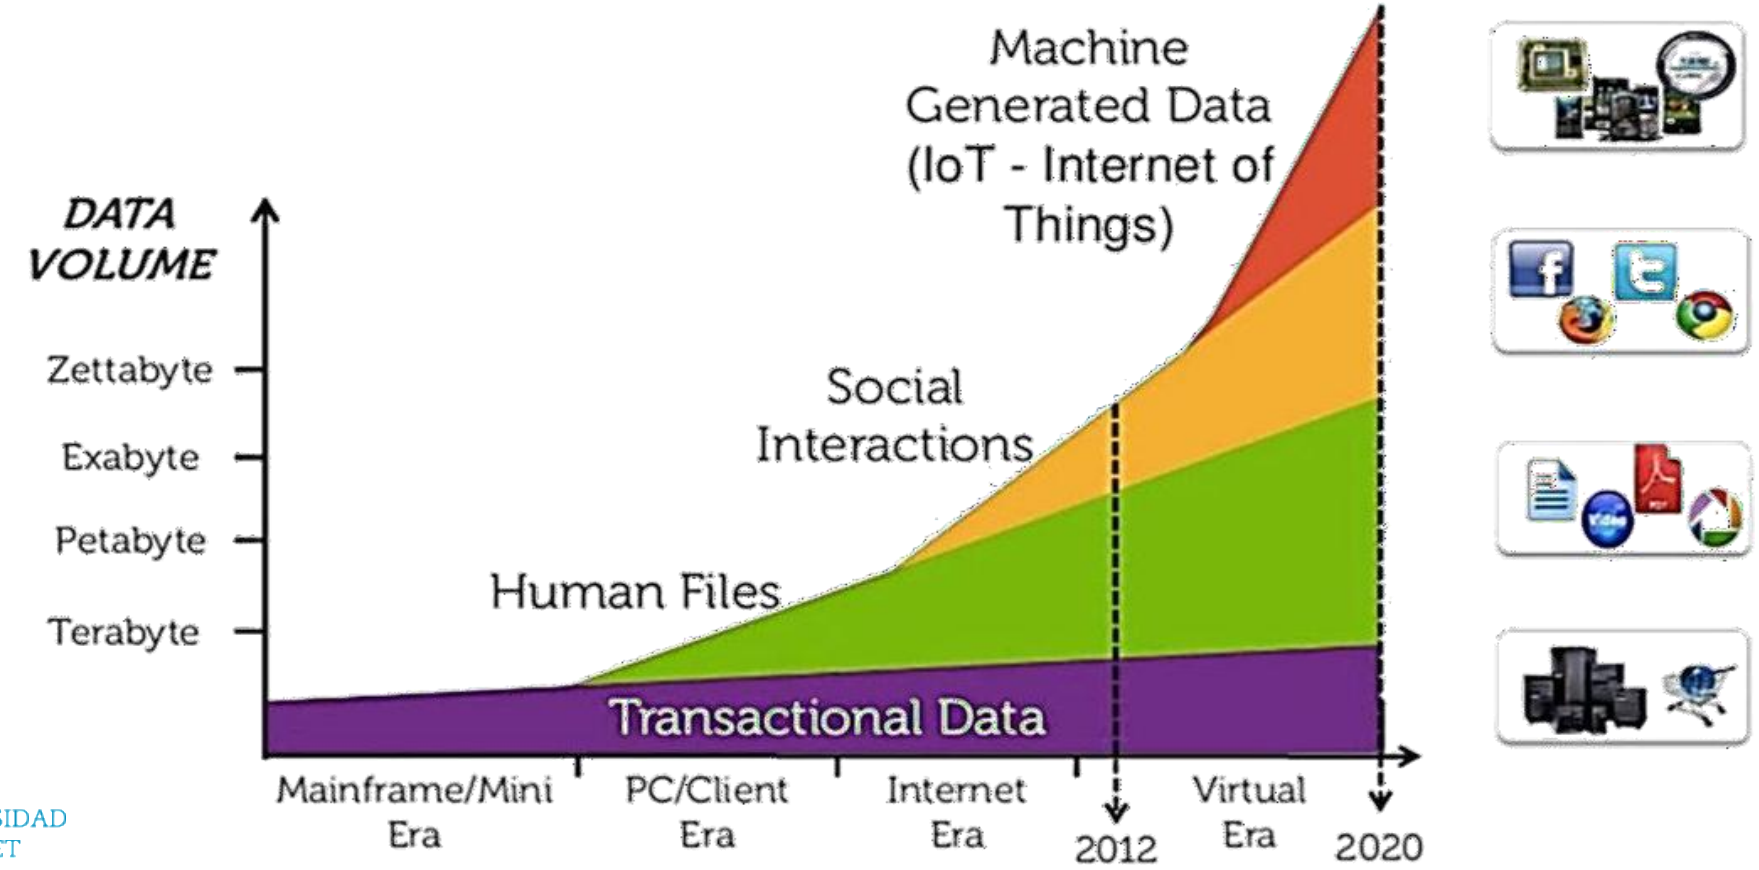

Fuentes (orígenes) de datos en la actualidad

- **Interacciones** persona – persona
  - Email (texto), redes sociales (imágenes,vídeos, texto), foros de internet (texto)
  - Datos no estructurados al contener la vida cotidiana de las personas

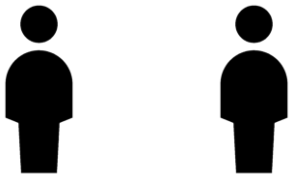

- **Interacciones** persona – máquina
  - Navegación en internet:
    - Logs generados cuando navegamos por sitios web
    - Datos generados cuando hacemos transacciones bancarias, compras online (viajes, entradas, hoteles, Amazon).
    - Representan interacciones digitales de un cliente con una empresa
  - Datos estructurados o semi-estructurados

- **Interacciones** entre máquinas
  - Datos generados por sensores (Internet of Things, IoT)
  - Datos perfectamente estructurados al estar generados por máquinas

Motivación de las tecnologías Big Data

Motivación de las tecnologías Big Data

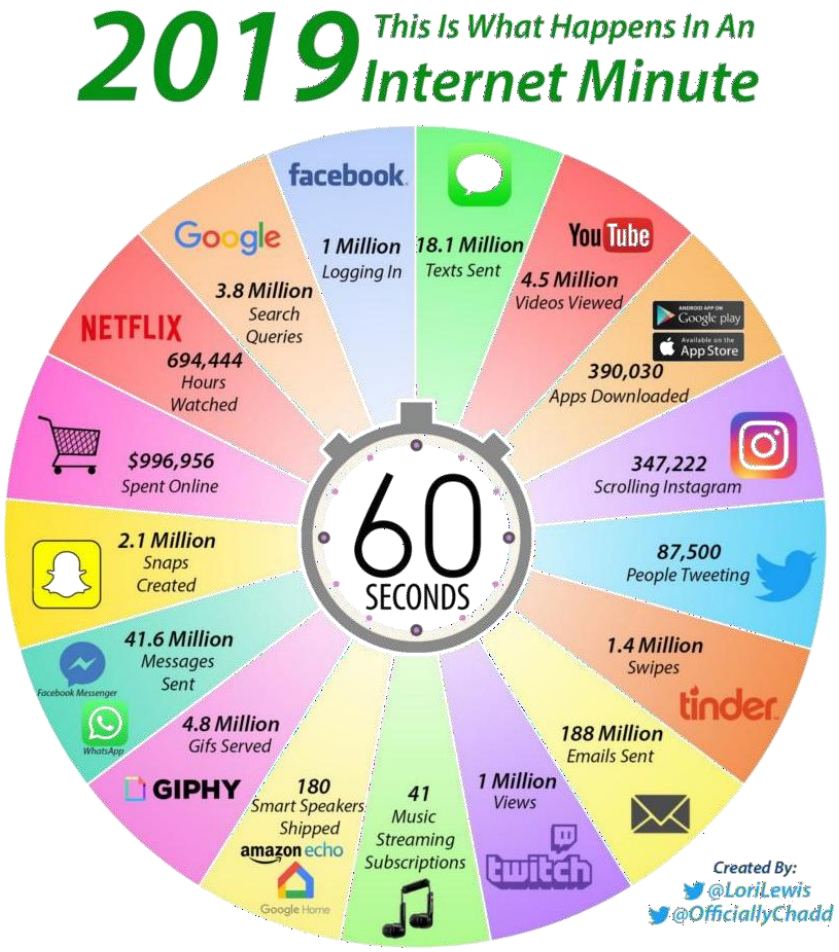

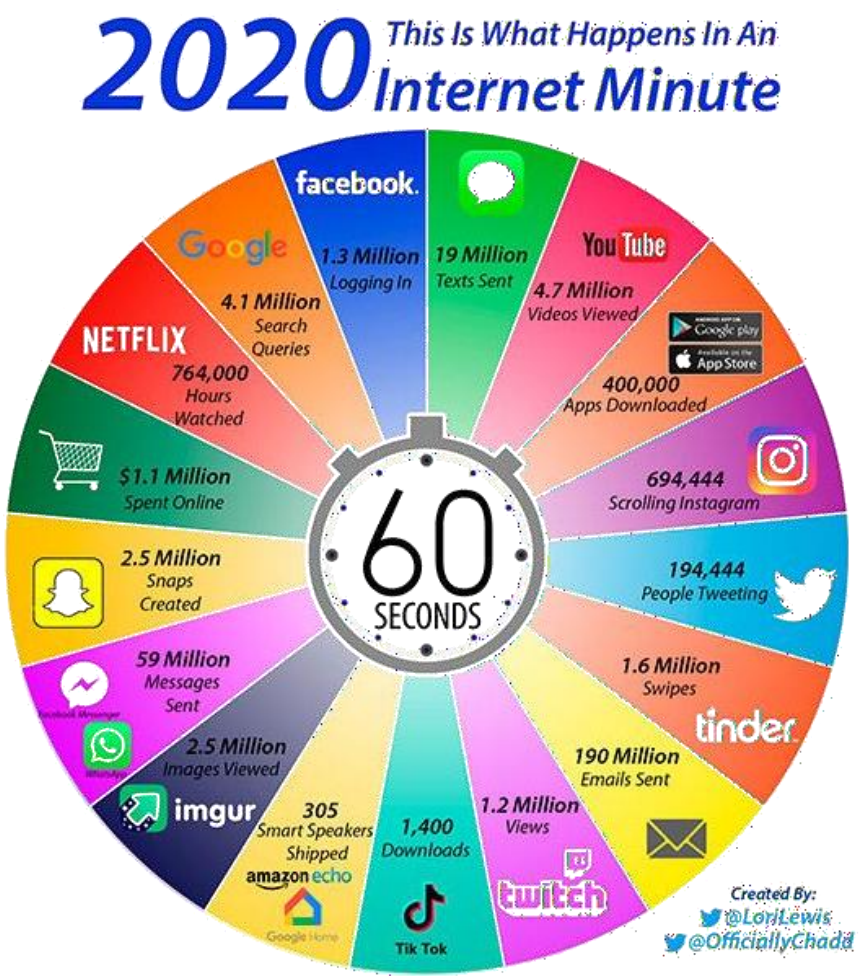

Motivación de las tecnologías Big Data

Motivación de las tecnologías Big Data

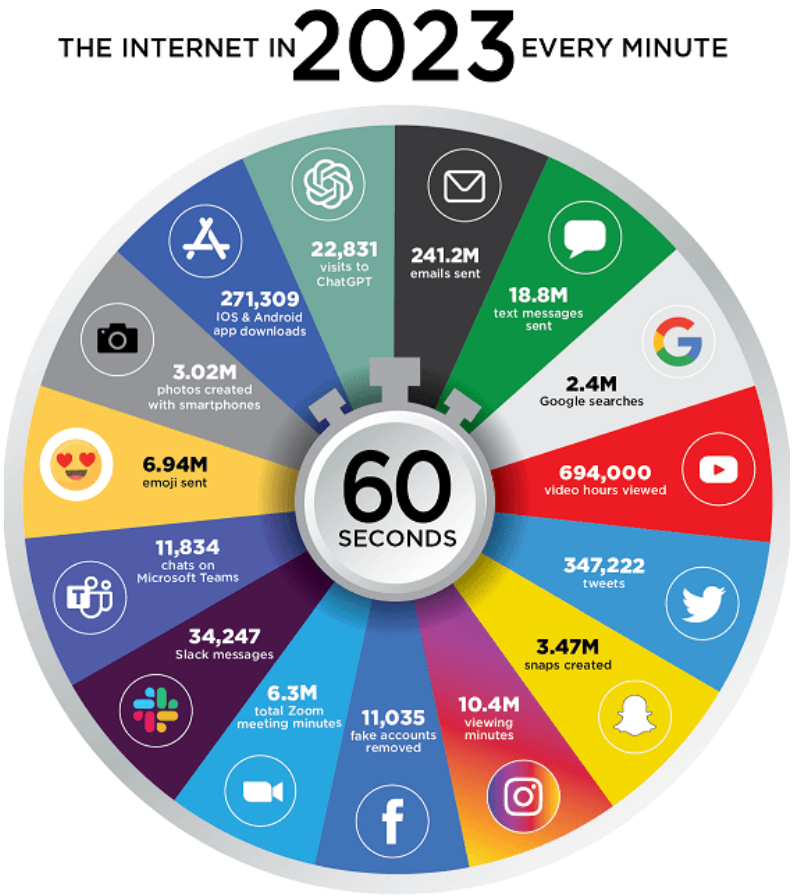

La Transformación Digital en torno al dato

- Más interacciones digitales que físicas entre personas y sus compañías
  - Energía, empresas de telefonía, tiendas online, banca online
  - Cada interacción genera **datos** que hablan de los **clientes** (nosotros)
  - ¡**Nosotros** evolucionamos más rápido que las compañías!
    - Hueco entre las compañías tradicionales y nuestra forma de vivir

- **Transformación Digital** para adaptarnos al nuevo cliente:
  - Centrarse en el cliente (*customer centricity*): mejorar su experiencia, prever sus necesidades y **su comportamiento**: analizando sus datos
  - Centrarse en lo que ocurre en los **canales digitales**: genera datos
  - Decisiones **guiadas por los datos** (convertirse en **data driven**)
    - **(Big) Data Science**: los clientes generan **muchísimos** datos

Motivación de las tecnologías Big Data

- En la era del cliente, éste genera grandes cantidades de datos que una sola máquina no puede almacenar ni procesar
  - Procesamiento distribuido entre varias máquinas (clúster), cada una no necesariamente muy potente (***commodity hardware***)
  - ¿Más capacidad? (datos, memoria o CPU) → se añaden nodos
- Datos no estructurados (imágenes, vídeo, documentos) que las BBDD relacionales no pueden manejar
  - Solución: **BBDD NoSQL** (Hadoop ya incluye una: Apache HBase)

¿Qué es un proyecto Big Data?

- Un proyecto de datos se considera Big Data cuando implica alguna de las tres “V” :
  - **Volumen**: cantidades de datos lo suficientemente grandes como para no poderse procesar con tecnologías tradicionales.
  - **Velocidad**: flujos de datos que van llegando en tiempo real y tienen que procesarse de manera continua según se van recibiendo.
  - **Variedad**: datos de fuentes diversas, estructuradas y no estructuradas (sean BBDD relacionales, no relacionales, datos de imágenes, sonido, etc.) que tienen que ser manejados y cruzados de manera conjunta.

Motivación de las tecnologías Big Data

- Una definición realista sería:

  Un proyecto es Big Data cuando la mejor manera de resolverlo (más rápida, eficiente, sencilla) implica utilizar tecnologías Big Data.

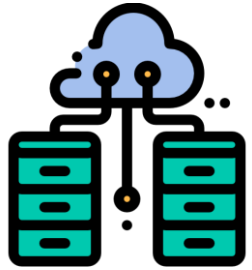

Causas de esa imposibilidad:

- Cantidades ingentes de datos **inimaginables** hace unos años.
- Datos de fuentes diversas, **heterogéneas**, poco estructuradas como documentos o imágenes/sonido, que aun así necesitamos almacenar y consultar (NoSQL).
- Datos dinámicos recibidos y procesados según llegan (flujos de datos o *streams*).

Big Data: conjunto de **tecnologías** y **arquitecturas** para almacenar, mover, acceder y procesar (incluido analizar) datos que eran muy difíciles o imposibles de manejar con tecnologías tradicionales.

Aspecto de un clúster en la actualidad

Mare Nostrum 4 Barcelona Supercomputing Center (CSIC)

Top 500 de clusters más potentes (Junio 2021)

Rank	System	Cores	Rmax (TFlop/s)	Rpeak (TFlop/s)	Power (kW)
1	**Supercomputer Fugaku** - Supercomputer Fugaku, A64FX 48C 2.2GHz, Tofu interconnect D, Fujitsu RIKEN Center for Computational Science Japan	7,630,848	442,010.0	537,212.0	29,899
2	**Summit** - IBM Power System AC922, IBM POWER9 22C 3.07GHz, NVIDIA Volta GV100, Dual-rail Mellanox EDR Infiniband, IBM DOE/SC/Oak Ridge National Laboratory United States	2,414,592	148,600.0	200,794.9	10,096
3	**Sierra** - IBM Power System AC922, IBM POWER9 22C 3.1GHz, NVIDIA Volta GV100, Dual-rail Mellanox EDR Infiniband, IBM / NVIDIA / Mellanox DOE/NNSA/LLNL United States	1,572,480	94,640.0	125,712.0	7,438
4	**Sunway TaihuLight** - Sunway MPP, Sunway SW26010 260C 1.45GHz, Sunway, NRCPC National Supercomputing Center in Wuxi China	10,649,600	93,014.6	125,435.9	15,371
5	**Perlmutter** - HPE Cray EX235n, AMD EPYC 7763 64C 2.45GHz, NVIDIA A100 SXM4 40 GB, Slingshot-10, HPE DOE/SC/LBNL/NERSC United States	706,304	64,590.0	89,794.5	2,528

Top 500 de clusters más potentes (Noviembre 2023 y Junio 2024)

Rank	System	Cores	Rmax (PFlop/s)	Rpeak (PFlop/s)	Power (kW)
1	**Frontier** - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, HPE DOE/SC/Oak Ridge National Laboratory United States	8,699,904	1,194.00	1,679.82	22,703
2	**Aurora** - HPE Cray EX - Intel Exascale Compute Blade, Xeon CPU Max 9470 52C 2.4GHz, Intel Data Center GPU Max, Slingshot-11, Intel DOE/SC/Argonne National Laboratory United States	4,742,808	585.34	1,059.33	24,687
3	**Eagle** - Microsoft NDv5, Xeon Platinum 8480C 48C 2GHz, NVIDIA H100, NVIDIA Infiniband NDR, Microsoft Microsoft Azure United States	1,123,200	561.20	846.84	
4	**Supercomputer Fugaku** - Supercomputer Fugaku, A64FX 48C 2.2GHz, Tofu interconnect D, Fujitsu RIKEN Center for Computational Science Japan	7,630,848	442.01	537.21	29,899
5	**LUMI** - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, HPE EuroHPC/CSC Finland	2,752,704	379.70	531.51	7,107

Top 500 de clusters más potentes (Junio 2025)

Rank	System	Cores	Rmax (PFlop/s)	Rpeak (PFlop/s)	Power (kW)
1	**El Capitan** - HPE Cray EX255a, AMD 4th Gen EPYC 24C 1.8GHz, AMD Instinct MI300A, Slingshot-11, TOSS, HPE DOE/NNSA/LLNL United States	11,039,616	1,742.00	2,746.38	29,581
2	**Frontier** - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, HPE Cray OS, HPE DOE/SC/Oak Ridge National Laboratory United States	9,066,176	1,353.00	2,055.72	24,607
3	**Aurora** - HPE Cray EX - Intel Exascale Compute Blade, Xeon CPU Max 9470 52C 2.4GHz, Intel Data Center GPU Max, Slingshot-11, Intel DOE/SC/Argonne National Laboratory United States	9,264,128	1,012.00	1,980.01	38,698
4	**JUPITER Booster** - BullSequana XH3000, GH Superchip 72C 3GHz, NVIDIA GH200 Superchip, Quad-Rail NVIDIA InfiniBand NDR200, RedHat Enterprise Linux, EVIDEN EuroHPC/FZJ Germany	4,801,344	793.40	930.00	13,088
5	**Eagle** - Microsoft NDv5, Xeon Platinum 8480C 48C 2GHz, NVIDIA H100, NVIDIA Infiniband NDR, Microsoft Azure Microsoft Azure United States	2,073,600	561.20	846.84	

Top 500 de clusters más potentes (Junio 2025)

El Capitán (EE. UU.) – Superordenador del Laboratorio Nacional Lawrence Livermore, basado en arquitectura AMD, con un rendimiento esperado superior a **2 exaFLOPS** (operativo en 2025)

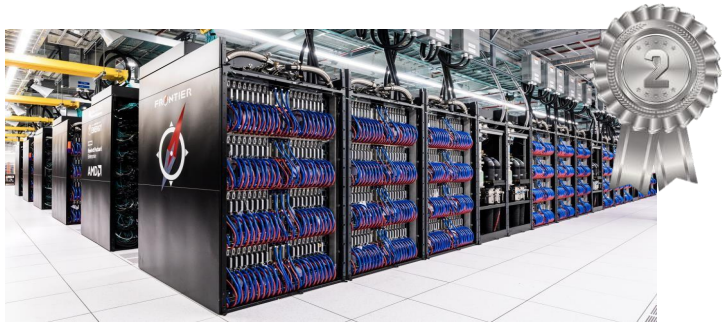

Frontier (EE. UU.) – Ubicado en el Laboratorio Nacional Oak Ridge, también con tecnología AMD, con un rendimiento de alrededor de **1,68 exaFLOPS**, actualmente el más rápido del mundo (desde 2022)

Aurora (EE. UU.) – Instalado en el Laboratorio Nacional Argonne, usa procesadores **Intel Xeon Max y GPU Intel Ponte Vecchio**, con un rendimiento proyectado cercano a **2 exaFLOPS**

Historia de Hadoop y Spark

- Google (C++) - Almacenamiento + procesamiento usando commodity hardware
  - 2003 - Google File System (GFS) – **el germen de HDFS**
    http://static.googleusercontent.com/media/research.google.com/es//archive/gfs-sosp2003.pdf
  - 2004 - Map Reduce (Simplified Data Processing on Large Clusters).
    http://static.googleusercontent.com/media/research.google.com/es//archive/mapreduce- osdi04.pdf
- Apache Hadoop (Java)
  - 2002, Doug Cutting desarrolla Nutch. 2006, Hadoop se independiza de Nutch
  - 2008, se hace open-source (incluye una implementación abierta de MapReduce)
  - Adoptado en grandes empresas de todo el mundo a partir del año 2011

Historia de Hadoop y Spark

- Apache Spark (Scala) – Motivado por procesos iterativos (Machine Learning)
  - 2009 - Matei Zaharia (era su tesis doctoral en UC Berkeley, grupo AMPLab)
  - 2010 - Open Source
  - 2014 - Forma parte de Apache 2.0. Top Level Project
  - 2015 - Más de 1000 contributors
  - 2016+ La mayoría de clústeres de Hadoop son migrados a Spark.

Historia de Hadoop y Spark

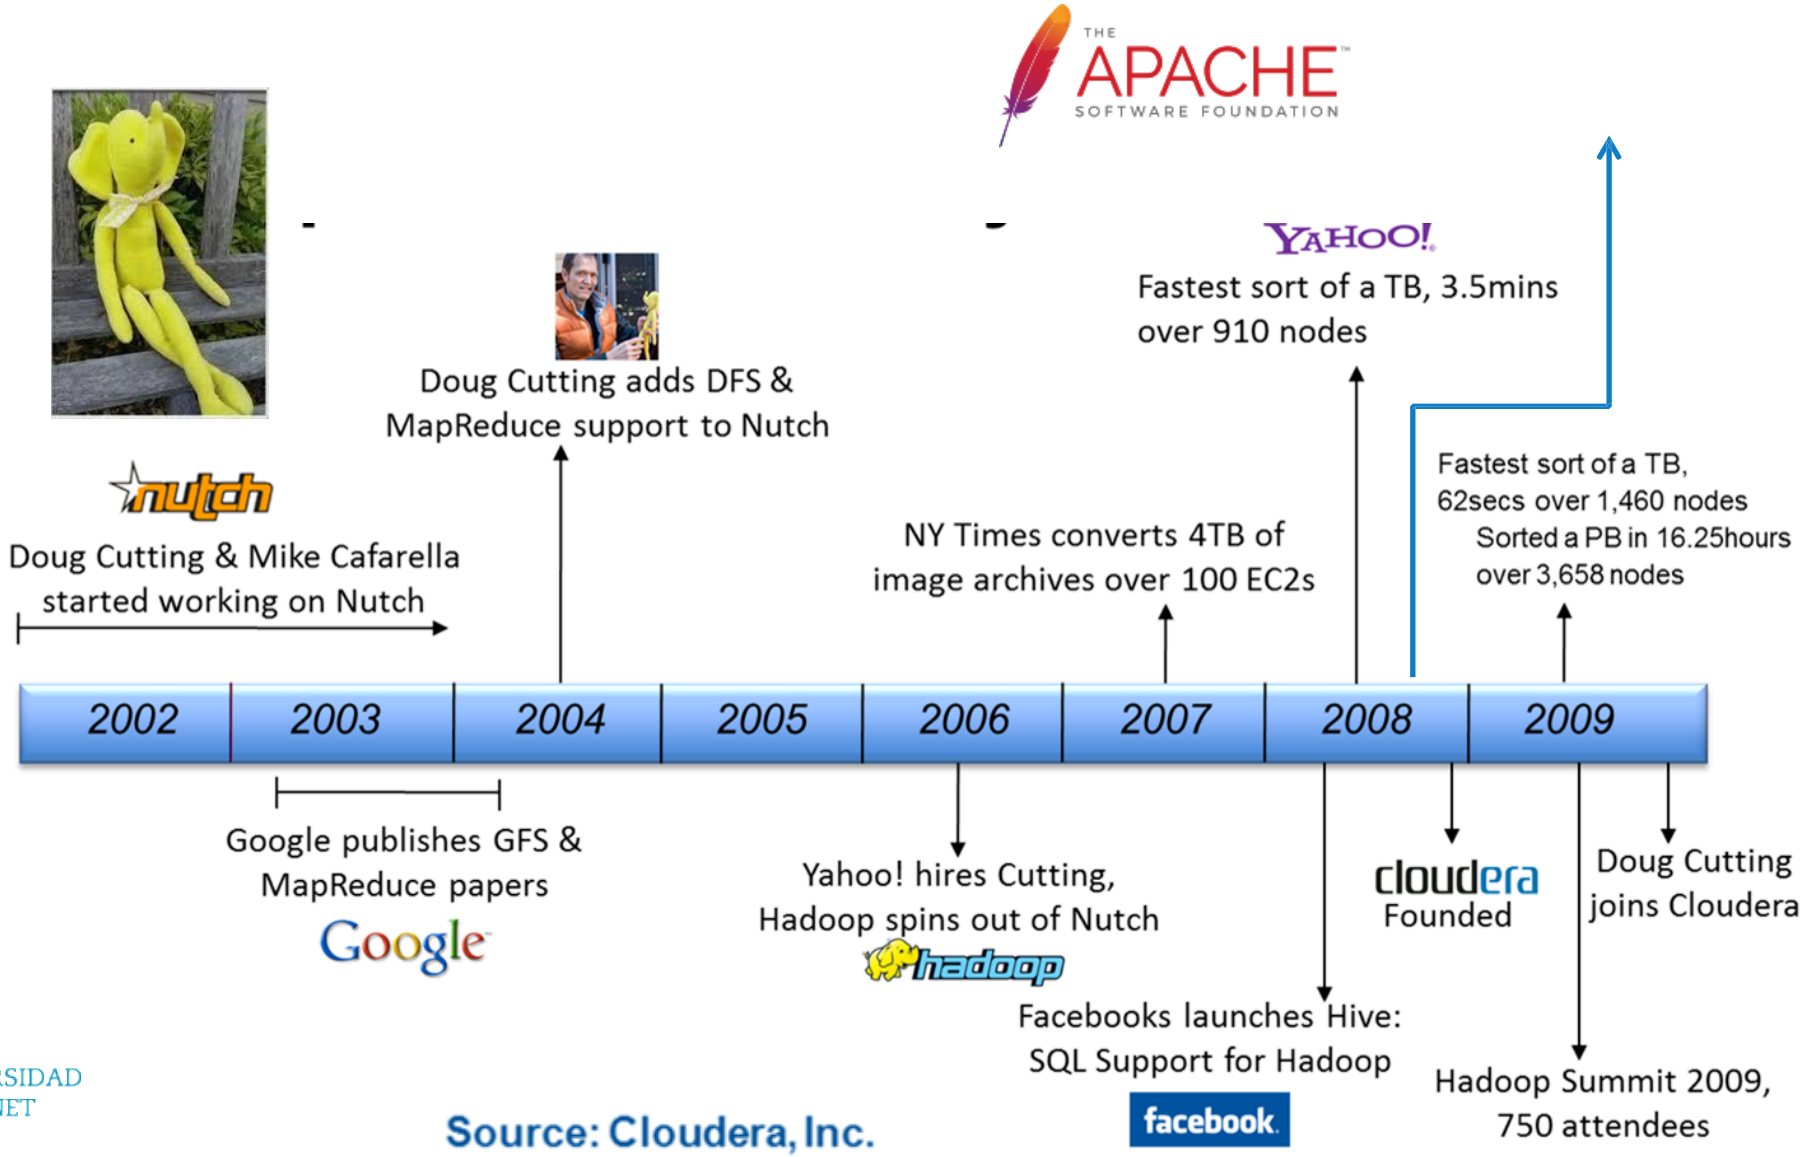

Source: Cloudera, Inc.

Historia de Hadoop y Spark

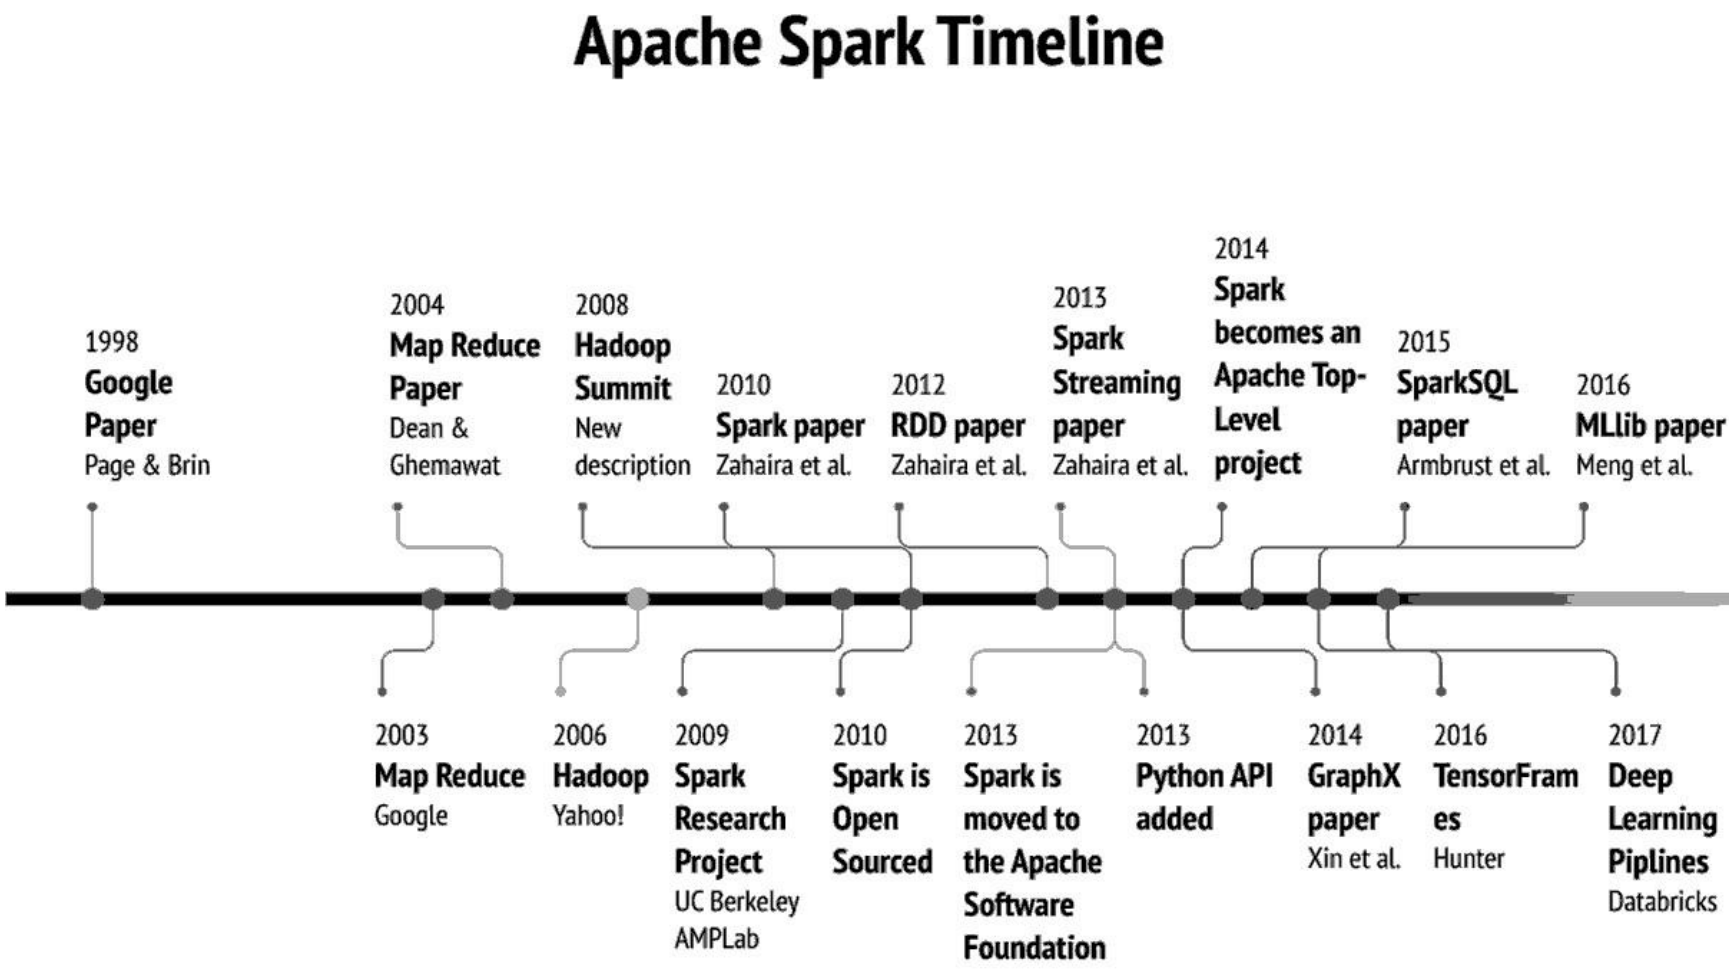

Historia de Hadoop y Spark

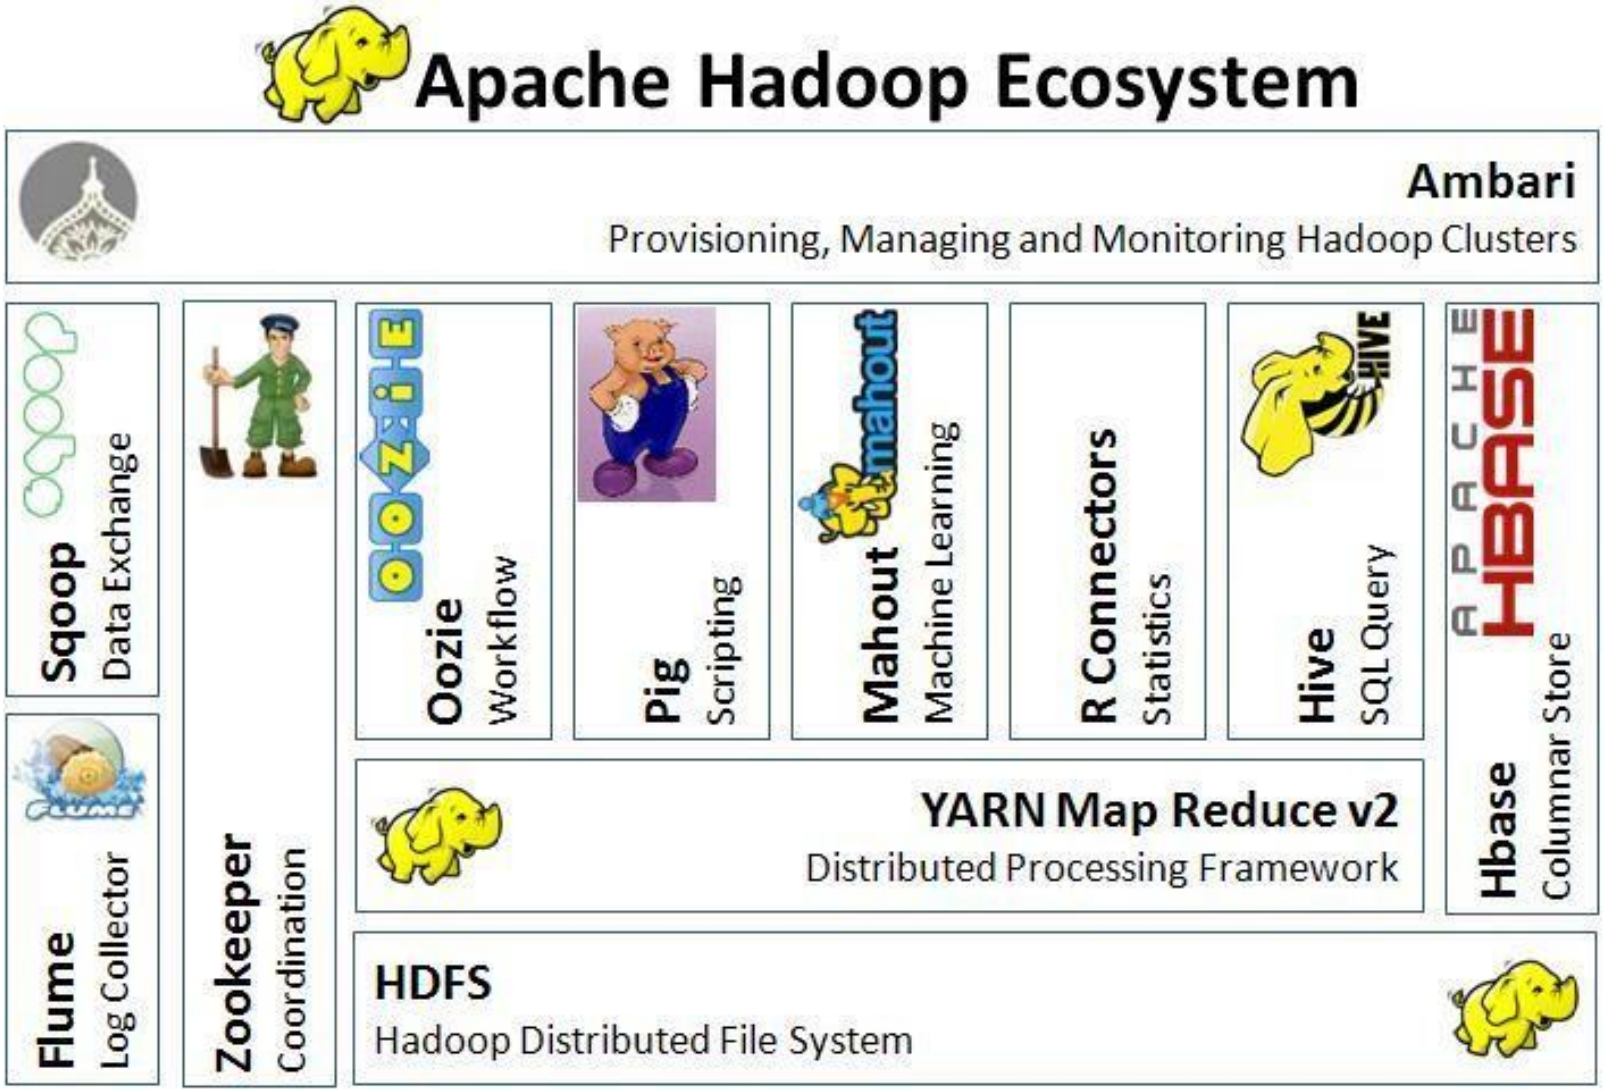

Componentes de Hadoop

- **HDFS (Hadoop Distributed File System):** sistema de archivos distribuido inspirado en el GFS de Google, que permite distribuir los datos entre distintos nodos de un clúster, gestionando la distribución y la redundancia de forma transparente para el desarrollador que vaya a hacer uso de esos datos.

- **Apache Hive:** herramienta para acceder mediante sintaxis SQL a datos estructurados que están almacenados en un sistema de archivos distribuido como HDFS u otros similares. Las consultas SQL son traducidas automáticamente a trabajos de procesamiento distribuido

- **Apache Spark:** motor de procesamiento distribuido y bibliotecas de programación distribuida de propósito general, que opera siempre en la memoria principal (RAM) de los nodos del clúster. Desde hace unos años ha reemplazado totalmente a MapReduce al ser mucho más rápido.

- **Apache Kafka:** plataforma para manejo de eventos en tiempo real, que consiste en una cola de mensajes distribuida y masivamente escalable sobre un clúster de ordenadores para ser consumidos por uno o varios procesos externos (por ejemplo trabajos de Spark).

Distribuciones de Hadoop

- Todos los componentes de Hadoop se puede descargar e instalar de forma independiente (requiere configuración posterior)

- Distribución de Hadoop: producto software con todos los componentes de Hadoop preinstalados en versiones que interoperan bien entre ellas, y con soporte adicional.

- Sandbox: máquina virtual que emula un sistema operativo con el software pre-instalado, listo para ejecutar sin requerir instalación.

Distribuciones de Hadoop

Característica	Cloudera	Hortonworks	MapR
Componentes	Apache modificados y añadidos	Sólo Apache oficiales	Apache y añadidos
Versiones	Open-source (CDH) y de pago	Sólo 100 % open-source	Open-source y de pago
Sistema operativo	Linux (Windows: VM Ware)	Linux y Windows	Linux (Windows: VM Ware)
Año de creación	2008	2011	2009
Observaciones	Es la más extendida. Certificación muy popular.	Única para Windows, y única 100 % open-source	La más rápida y fácil de instalar

Para profundizar ...

- El papel del big data en la transformación digital : Newman, D. (2015, 22 de diciembre). The role big data plays in digital transformation. F o r b e s . https://www.forbes.com/sites/danielnewman/2015/12/22/the-role-big-dataplays-in-digital-transformation/

- Historia de Hadoop: producto software con todos los componentes de Hadoop preinstalados en versiones que interoperan bien entre ellas, y con soporte adicional.

- Leading digital: turning technology into business transformation: Westerman, G., Bonnet, D. y McAfee, A. (2014) Leading digital: turning technology into business transformation. Harvard Business Review Press.

- Digital transformation: a model to master digital disruption: Caudron, J. y Van Peteghem, D. (2018) Digital transformation: a model to master digital disruption (3. a edición). BookBaby.

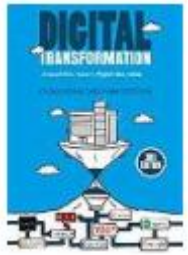

Dudas y preguntas

¡MUCHAS GRACIAS¡

unir
LA UNIVERSIDAD
EN INTERNET