Tema 4. Apache Spark II

PER 14624 Noviembre 2025

Objetivos del tema

- Conocer la API estructurada de Spark y su principal estructura de datos, el DataFrame.
- Identificar las ventajas de usar DataFrames en lugar de RDD.
- Conocer Spark SQL, así como sus similitudes y diferencias con la API estructurada.
- Practicar con algunas funciones típicas de procesamiento de DataFrames, tanto con la API estructurada como con Spark SQL.

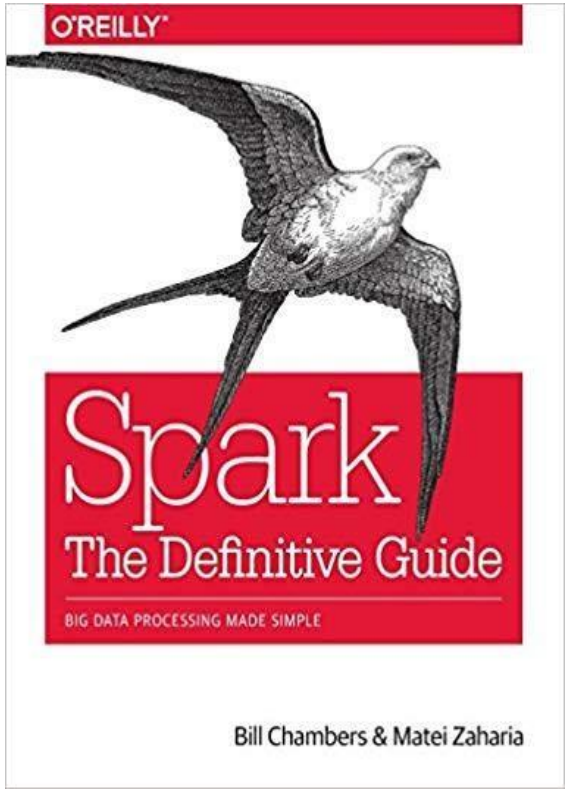
O'REILLY
Spark
The Definitive Guide
BIG DATA PROCESSING MADE SIMPLE
Bill Chambers & Matei Zaharia

DataFrames y Spark SQL

- El cálculo con RDD es tedioso y de bajo nivel. **Spark SQL** nace para manejar datos intrínsecamente *estructurados*, como si manejásemos tablas distribuidas en memoria
  - Es posible usar Spark SQL para procesar JSON, pero sólo *tras asignarle un esquema* para convertirlo a tabla
- *DataFrame*: RDD + esquema (tipos y nombres de columnas) que se maneja *como si fuese* una tabla de una base de datos.
  - Esquema explícito, o bien inferido por Spark
  - Un DataFrame no es más que un RDD de objetos de tipo *Row* («fila»), el cual es similar a un array: cada fila se asemeja a un vector de elementos con nombre
  - Podemos obviar este detalle ya que siempre vamos a **manejarlos utilizando la API Estructurada** (operaciones propias de los DataFrames)

- Introducidos en Spark 1.6 (año 2016). A partir de Spark 2.0 se considera la estructura de datos fundamental para la API de Spark

DataFrames: "tablas distribuidas en memoria"

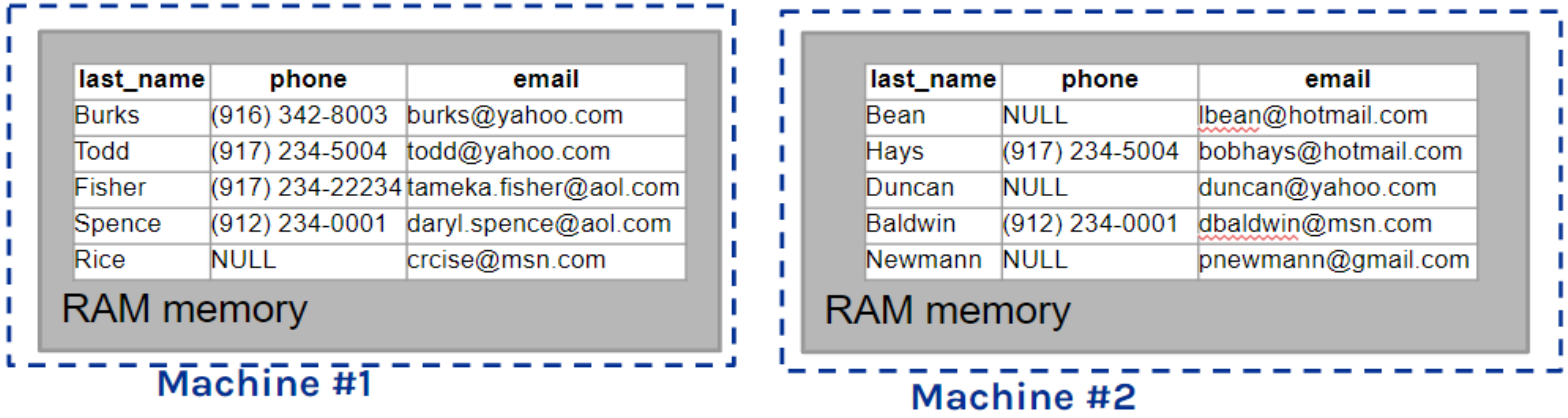

DataFrame

	Name	Age	City	Country
Part #1	Pablo	24	Barcelona	Spain
	Emma	32	Alabama	USA
Part #2	Tony	28	Frankfurt	Germany
	Jose	35	Madrid	Spain

=

RDD de Rows

Part #1	Row(Name=Pablo, Age=24, City=Barcelona, Country=Spain) Row(Name=Emma, Age=32, City=Alabama, Country=USA])
Part #2	Row(Name=Tony, Age=28, City=Frankfurt, Country=Germany) Row(Name=Jose, Age=35, City=Madrid, Country=Spain)

```
resultadoDF = personas.select("Age", "Country").where("Age >= 18 and Country == 'Spain' ")
```


Documentación oficial del módulo Spark SQL: https://spark.apache.org/docs/latest/sql-programming-guide.h5tml
Documentación oficial de la API de pyspark: https://spark.apache.org/docs/latest/api/python/index.html

Manipulación de DataFrames: Spark SQL API

- Existe una API para manejar DataFrames: ***API estructurada*** (paquete **SparkSQL)**
- Vamos a ver las transformaciones y acciones más frecuentes sobre DataFrames

Acción *count():* cuenta las filas del DF y devuelve al driver un entero:

Acción *show(n=20):* lleva al driver el número indicado de filas (20 si no se indica nada) y lo imprime por pantalla. **No devuelve ningún resultado (devuelve *None* de Python)**

Acción *collect():* lleva al driver **todas** las filas del DF como una **lista de objetos *Row*, y la devuelve como resultado. PRECAUCIÓN:** deben caber en el driver o dará error!

Acción *take(n):* lleva una lista de *n Rows* al driver. Los *n* primeros si el DF fue ordenado

```
numFlights = flightsDF.count()     # materializa flightsDF
flightsDF.cache()                 # para la próxima, no liberar
flightsDF.show(30)                 # materializa flightsDF parcialmente
listaTodos = flightsDF.collect()   # una parte ya estaba materializada
flightsOrdenados = flightsDF.sort("ArrDelay") # Aquí no hace nada
menorRetraso = flightsOrdenados.take(10) # Aquí se hace sort y take
for r in menorRetraso:   # recorremos una lista de Python
    print(r.ArrDelay)    # acceso a columnas de un Row con '.'
```

Manipulación de DataFrames: Spark SQL API

Transformación *select*

- Recibe los nombres de las columnas que queremos seleccionar y devuelve otro DF que solo contiene esas columnas Todas las columnas deben existir!

```
transformedDF = flightsDF.select("Year", "Month",
                                 "DayofMonth", "ArrTime", "FlightNum")
```

- También podemos usarlo para crear nuevas columnas al vuelo: `from pyspark.sql`

```
import functions as F  resultDF = flightsDF.select(
   F.col("Year"),
   F.col("Distance"), (1.6*F.col("Distance")).alias("DistKm")
 )

 resultDF.show()
```

Year	Distance	DistKm
2008	2400	3840
2008	3200	5120
2008	1500	2400
2008	4500	7200

Manipulación de DataFrames: Spark SQL API

Transformación *where / filter*

- Devuelve un nuevo DF que contiene solo las filas que cumplen cierta condición booleana sobre una o más columnas
  - filter() y where() son exactamente equivalentes
  - El argumento puede ser un string con una condición en SQL puro
  - También puede ser una condición booleana utilizando la API de SparkSQL API sobre las columnas

```
from pyspark.sql import functions as F transformedDF =
flightsDF\
    .filter("DayOfMonth < 20 or Origin = 'LAX'")\ # SQL puro
    .filter("Carrier is not null")\            # SQL puro
    .filter(~(F.col("FlightNum").isNull()))\ # API estructurada
    .filter(1.6*F.col("Distance") > 5000)\   # API estructurada
    .filter(F.col("Delay") > F.col("DepDelay") + F.col("ArrDelay"))\
    .where("Delay > 15")           # SQL puro
```

Manipulación de DataFrames: Spark SQL API

Transformación *withColumn*

- Crea una nueva columna de otras existentes. Devuelve un nuevo DF que contiene todas las columnas existentes más la nueva por la derecha

```
from pyspark.sql import functions as F
transformedDF = flightsDF.withColumn("DistKm", 1.6*F.col("Distance"))
```

- Si el nombre corresponde a una columna ya existente, estaremos reemplazando (creándola de nuevo) en el nuevo DF en su misma posición

- Para la nueva columna se puede utilizar cualquier **operación entre columnas ya** implementada en Spark SQL en el paquete `pyspark.sql`
  `.functions` (todas son operaciones ya distribuidas)
  - Se suelen encadenar múltiples operaciones withColumn una tras otra.
  - Las nuevas columnas se van creando por la derecha en el mismo orden en el que vamos encadenando las operaciones.

Manipulación de DataFrames: Spark SQL API

Transformación *withColumn*

```
from pyspark.sql import functions as F

transformedDF = flightsDF\          # primero creamos una nueva
  .withColumn("DistKm", 1.6*F.col("Distance"))\ # columna
  .withColumn("TotalDelay", F.col("DepDelay")+ F.col("ArrDelay"))\
  .withColumn("Year", F.lit(2009)) # reemplazar columna existente

transformedDF.show()
```

Year	…	…	DistKm	TotalDelay
2009	…	…	3840	26
2009	…	…	5120	17
2009	…	…	2400	32
2009	…	…	7200	7

Manipulación de DataFrames: Spark SQL API

Transformación *drop*

- Elimina una o varias columnas, por nombre. Si no existen, NO da error.
- Devuelve un nuevo DF sin esas columnas (el DF original no se modifica)

Transformación *withColumnRenamed*

- Devuelve un nuevo DF donde una columna se ha renombrado en su misma posición

```
transformedDF = flightsDF\
 .withColumnRenamed("Delay", "MinutesLate")\ # nuevo nombre
 .drop("Carrier", "FlightNum", "inventedName") # es correcto
```

Transformación *sort / orderBy*

- Devuelve un nuevo DF ordenado en base a las columnas indicadas. Se utiliza la primera, y las demás solo para desempatar en caso de empate

```
sortedDF = flightsDF.sort("Origin", "flightDate", ascending=False) sortedDF.show(10) # los 10
primeros
```

Manipulación de DataFrames: Spark SQL API

Algunas funciones para operar con columnas

- Función ***col*** : construye un objeto Column de un nombre de columna
- Función ***alias***: devuelve un nuevo objeto Column renombrado
- La más frecuente es ***when***, que devuelve un objeto columna o una constante en función de condiciones booleanas sobre otras columnas
  - Se indica el valor que debe tener cada fila, y puede ser una constante o también el resultado de operar con columnas
  - Muy habitual para re-categorizar variables existentes o para calcular variables nuevas (ingeniería de variables, *feature engineering*)

```
from pyspark.sql import functions as F transformedDF
= flightsDF\
 .withColumn("retraso",
           F.when(F.col("ArrDelay") < 15, "puntual")\
            .when((F.col("ArrDelay") > 15) & (F.col("ArrDelay") < 60), "impuntual")\
            .otherwise("inaceptable"))\
 .withColumn("ArrDelay", F.when(F.col("ArrDelay") < 0, 0)\
                        .otherwise(F.col("ArrDelay")))
```

Manipulación de DataFrames: Spark SQL API

Algunas funciones para operar con columnas

- Agregación: F.mean("colName"), F.min, F.max, F.stddev, F.corr , …
- Columna constante: F.lit("valor")

Transformación para eliminar filas duplicadas y valores nulos

```
resultDF = df1.distinct()    # duplicado = coincidencia en todas las columnas
resultDF = flightsDF.dropDuplicates(subset = ["Origin", "Dest"]) resultDF =
flightsDF.dropna()              # quitar si hay NA/NULL en alguna columna
resultDF = flightsDF.dropna(subset = ["ArrDelay"]) # sólo si hay NA en ArrDelay
```

Transformación *union, intersect, except* (todos los DF deben tener mismo esquema)

```
resultDF = df1.union(df2).intersect(df3).except(df4)
```

Manipulación de DataFrames: Spark SQL API

Transformación *groupBy* seguida de *agg*

- Transformación para agregar por grupos
- Como estamos creando columnas nuevas con cada agregación, debemos ponerles un nombre mediante .alias(…)

```
agregadosDF = flightsDF.groupBy("Origin", "Dest")\
                    .agg(F.mean("ArrDelay").alias("retrasoMedioRuta"),
                        F.count("*").alias("recuento"))
```

Transformación *groupBy* + *pivot* seguida de *agg*

- Igual, pero una de las columnas agrupadoras (categórica) se despliega en tantas columnas como categorías tenga esa columna
- Cada grupo lo forman cada combinación de las variables de groupBy + la variable de pivot

```
agregadosDF = flightsDF.groupBy("origin", "dest")\
                    .pivot("month")\
                    .agg(F.count("*").alias("ignorado"))\
                    .fillna(0) # algunas combinac no existen en los datos
```

origin	dest	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
SEA	RNO	31	27	31	30	31	7	0	0	0	0	0	0
SEA	DTW	79	72	93	110	113	140	148	148	167	175	169	158
SEA	CLE	6	0	0	0	0	7	14	11	2	0	0	0

Manipulación de DataFrames: Spark SQL API

- Además de la API, existe un método para ejecutar tal cual consultas en SQL: el método **sql**("consultaComoString") que se invoca sobre la SparkSession

```
# Creamos una vista volátil que desaparecerá al cerrar Spark
flightsDF.createOrReplaceTempView("flights") # metadatos en Hive resultDF =
spark.sql("select Origin from flights
                        where ArrDelay > 15")
```

- Soporta consultas SQL complejas y las traduce a trabajos de Spark optimizados
  - Recordemos: motor de ejecución único
  - La API estructurada es igual de eficiente que efectuar consultas en SQL a Spark porque al final se traducen a un mismo plan de ejecución abstracto.

Lectura y escritura de DataFrames

- Lectura de datos de un datasource, que por defecto es HDFS

```
myDF = spark.read.format(<formato>).load("/path/to/hdfs/file")
```

<formato> = “parquet” | “json” | “csv” | “orc” | “avro”, y *spark* es el objeto SparkSession

- Suele estar disponible un atajo con `spark.read.<format>("/path/to/file")` aunque no todos los formatos lo tienen

```
df1 = spark.read.option("inferSchema", "true")\
              .csv("/path/to/file") # infiere

df2 = spark.read.option("inferSchema", "false")\
              .csv("/path/to/file") # todas string

from pyspark.sql import types as T myschema =
T.StructType([
    T.StructField("columna1", T.DoubleType(), nullable = False),
    T.StructField("columna2", T.DateType(), nullable = False)])
df3 = spark.read.option("header", "true")\
            .option("delimiter", "|")\
            .schema(myschema).csv("/path/to/file")
```

User Defined Functions (UDF)

- Función que recibe datos de cada fila y devuelve un resultado. Se aplica a cada fila
- Similar a un *map* pero …
  - Aplicado a un DataFrame, donde intervienen solo ciertas columnas
  - Recibe el tipo simple de cada columna implicada (en vez de un objeto *Row*)
  - Se utiliza dentro de **withColumn()** para *crear una nueva columna a un DF existente, con el resultado de aplicar a cada fila nuestra función, en la que intervienen solo ciertas columnas de la entrada*.
  - En cambio, *map* devuelve un DF completamente nuevo (no añade columnas)

```
def computeInitialGroup(year1, year2): # year1 y year2 son strings
    if (year1 != "None_or_-1" and year1 != "Other"):
        return year1
    elif (year2 != "None_or_-1" and year2 != "Other"):
        return year2
    else:
        return "Unknown"

udfinitial_group = F.udf(computeInitialGroup, StringType())
# ... pero invocamos a nuestra UDF pasándole 2 columnas (de tipo string) myDF =
spark.read.parquet("/tmp/misdatos.parquet")
newDF = myDF.withColumn(“initialGroup”, udfinitial_group(
            F.col(“year1Col”), F.col(“year2Col”))
```

Dudas y preguntas

¡MUCHAS GRACIAS¡

unir
LA UNIVERSIDAD
EN INTERNET